

# 배기가스 온도 데이터를 활용한 선박 메인 엔진 결함 진단 및 예지

김태경<sup>1</sup>, 김세하<sup>1</sup>, 전창재<sup>2</sup>

Department of <sup>1</sup>Artificial Intelligence and <sup>2</sup>Artificial Data Science, Sejong University, Republic of Korea



## Abstract

선박 메인엔진의 결함을 조기에 발견하고 대처하는 것을 효율적이고 안전한 운항을 위해 매우 중요하다. 결함이 발생할 경우 경제적 손실과 안전의 위험이 증가할 수 있다. 그러나 현재 시점에서의 결함 진단은 이미 발생한 결함에 대해서만 대처할 수 있다는 한계가 있다. 따라서 본 논문에서는 실제 운항 환경에서 수집된 배기가스 온도 데이터를 활용하여 현재 시점에서의 결함 진단에서 더 나아가 미래 시점에서의 결함 진단으로 확장하여 선박 메인 엔진의 결함 진단을 위한 모의실험을 수행한다. 연구는 세 단계로 진행된다. 첫째, 현재 시점에서의 결함 진단에 여러 머신러닝 모델을 적용하여 가장 적합한 모델을 선정한다. 둘째, 미래의 시계열 데이터를 예측하는 Transformer 기반 모델을 설계하여 성능을 평가한다. 마지막으로 예측된 시계열 데이터를 기반으로 미래 시점에서의 결함 진단을 진행한다. 실험 결과, 예측된 미래의 시계열 데이터를 활용하여 결함 진단을 진행하여 78.160%의 정확도를 달성하였다.

## Methods

- 실제 환경에서 수집된 실린더 배기가스 온도 데이터셋을 사용하여 실험함.
  - 메인 엔진의 5개 실린더에 부착된 센서에서 측정된 데이터를 활용.
  - 각 데이터는 'ME(S) 1 CYL EXH GAS TEMP H', 'ME(S) 2 CYL EXH GAS TEMP H', 'ME(S) 3 CYL GAS TEMP H', 'ME(S) 4 CYL GAS TEMP H' 및 'ME(S) 5 CYL EXH GAS TEMP H'임.
  - 본 연구를 위해 5개의 센서로부터 수집된 데이터의 평균값을 사용.
- 1단계에서는 현재시점에서의 결함 진단에 가장 적합한 모델을 선정하기 위해 대표적인 머신러닝 기반 분류 모델인 Support Vector Machine (SVM), Artificial Neural Network (ANN), K-Nearest Neighbor (K-NN), Decision Tree, Light Gradient Bossting Machine (LGBM) 및 Random Forest를 사용하여 실험.
  - 시계열 데이터 샘플로부터 9개의 time domain features(최댓값, 최솟값, 평균, 표준편차, 중앙값, 왜도, 첨도, 25 백분위수 및 75 백분위수)를 추출하여 모델의 입력으로 사용.



Figure 1. 1단계 - 현재 시점에서의 결함 진단 흐름도

- 2단계에서는 미래의 시계열 데이터를 예측하기 위한 Transformer 기반 모델을 설계.



Figure 2. 2단계 - 미래의 시계열 데이터 예측 흐름도

- 3단계에서는 예측된 시계열 데이터를 사용하여 미래 시점에서의 결함 진단을 진행.




Figure 3. 3단계 - 미래 시점에서의 결함 진단 흐름도

## Results

### 1단계 실험 결과

Model	Accuracy
SVM	81.720%
ANN	82.796%
K-NN	87.869%
Decision Tree	90.312%
LGBM	90.984%
Random Forest	92.383%

Table 1. 머신러닝 기반 모델들의 결함 진단 실험 결과

Window Size	Stride	Accuracy
240	80	89.260%
120	40	92.383%
90	30	91.982%
60	20	92.307%
30	10	91.734%
20	6	91.254%
10	3	90.395%

Table 2. 총 7가지 경우의 window size와 stride의 조합에 따른 Random Forest를 활용한 결함 진단 비교 실험 결과

### 2단계 실험 결과

- 1단계 실험에서 가장 높은 정확도를 달성한 모델과 window 그리고 stride의 조합을 3단계 실험에 적용하기 위해서 예측된 미래의 시계열 데이터의 크기를 120으로 고정.

Window Size	RMSE	MAE
240	10.233	10.085
210	13.931	13.810
180	11.877	11.745
150	14.832	14.712
120	12.563	12.377

Table 3. 총 5가지 경우의 window size에 따른 Transformer 기반 모델을 활용한 시계열 데이터 예측 결과

### 3단계 실험 결과

- 1단계 실험과 2단계 실험에서 가장 높은 성능을 가진 설정을 채택하여 3단계 실험을 진행.
- 실험 결과, 78.160%의 정확도를 달성.

## Acknowledgement

본 연구는 과학기술정보통신부 및 정보통신기획평가원의 정보통신방송혁신인재양성(메타버스융합대학원) 사업 연구 결과로 수행되었음 (IITP-2024-RS-2023-00254529)